同一截止日，不同的持续性

点击量相近的学生之间，提交时机与截止后活动

第 9 组：刘嘉阳（50027216）、陈彦斌（50026846）、
王彦舜（50026688）、张育铭（50025933）

数据挖掘课程项目
2026 年 11 月

页数说明。正文在第 6 页结束；参考文献、披露与附录不计入 6–10 页的正文要求。本文件是英文报告的中文对照版。两份报告的表格与数字由同一条流水线生成；如出现不一致，以英文版为准。

1 研究问题

在线课程平台会为每一次资源浏览留下时间戳。点击总量是这份记录最直观的概括，也是预测谁会不及格时最直观的基线；然而两名学生可能点击次数完全相同，最终结果却差别很大。本项目要问的是：围绕一个强制截止日的活动时机，是否携带了点击量本身没有的信息。具体问题是：在同一课程批次内，在首次计分作业（TMA）截止后 14 天点击量相近的学生中，提交时机与截止后持续性是否与最终不及格（而非通过或优秀）相关？本报告把 Fail 作为正类，因此关心的指标是 Fail 的平均精确率（AP），参照值是同一批测试记录中 Fail 的占比。最终退课（Withdrawn）单独处理：它不进二分类比较，只在第 6 节的风险集描述里出现。三个设计选择定义了这项工作。第一，锚点不是开课日，而是每个批次第一个权重为正的 *TMA* 截止日，因为截止日才是大量学生要么提交、要么消失的时刻。第二，观察窗口对称：截止前 14 天（$d-13 \ldots d$）提供起点基线，截止后 14 天（$d+1 \ldots d+14$）才是关心的行为。第三，比较按截止后点击量配对，因此持续性的差异不能用一方点得更多来解释。本报告全部是观察性关联。配对是按最终结局构造的，所以样本在构造上就是 1:1，不能用它估计总体不及格率。截止日取作业表里的计划日期；OULAD 不记录个人延期，也不记录成绩公布日，因此提前或逾期只相对于计划日期，截点时已知成绩无从谈起。

2 数据与设计

数据是 Open University Learning Analytics Dataset（OULAD），公开版本包含 7 门课、22 个开课批次、32,593 条选课记录。分析单位是一条选课记录，因为同一名学生可能出现在多个批次里，而截止日是批次的属性。

样本流程步骤	记录数
全部选课记录	32593
存在首个正权重 TMA	30059
截止前已注册	29990
截点时仍在读	24594
排除承接旧成绩	469
结局已知	24125
截点时最终退课	4319
二分类记录	19806
其中 Fail	6092

表 1: 有序的入组流程。一条记录要进入分析，必须有首个正权重 TMA、在截止日前注册、在 $d+14$ 仍在读、且不是承接旧成绩。最终退课的记录不进二分类比较，但保留在第 6 节的风险集里。

32,593 条选课记录中，24,125 条满足全部入组规则；其中 4,319 条最终退课，19,806 条有二分类结局（6,092 条 Fail 对 13,714 条通过或优秀），Fail 占比为 30.8%。AAA–FFF 六门课共 19 个批次存在正权重 TMA；GGG 没有，因此不进入设计。时间特征来自日粒度点击流。对每条记录，流水线统计 $d-13$ 至 $d+14$ 每日点击，再派生截止后活跃天数、最长连续零点击天数、第二周点击占比、最高 7 天占比、日分布归一化熵、以及首次活动日。提交字段一律掩蔽到 $d+14$：更晚的提交视为未提交，两个指示变量加一个有符号的天数距离构成提交块。

3 配对比较

配对在每个批次内部进行。Fail 记录与点击量首先精确相等、其次在容差内的通过或优秀记录做 1:1 匹配；正点击要求比值上限，零点击只能和零点击配。任何记录不被重复使用。贪心顺序不保证全局最优，实际配对会被报告出来，以便检查残差。

容差	Fail 记录	配对	Fail 覆盖率	零点击配对	平均点击差	前段 SMD
0%	6092	4118	67.6%	607	0.0000	-0.306
5%	6092	4768	78.3%	607	0.0020	-0.287
10%	6092	4858	79.7%	607	0.0035	-0.279

表 2: 按截止后点击配对。5% 是主规格，0% 与 10% 为敏感性。前段标准化差被一并报告，因为配对故意不均衡截止前的窗口。

主配对得到 4,768 对 Fail，覆盖全部 Fail 的 78.3%，平均相对点击差 0.0020。截止后点击量几乎被完全均衡（标准化差 -0.000），但截止前的窗口没有：标准化差 -0.287，原始差 -20.6 次点击。Fail 在截止前就已经略不活跃，所以配对差值回答的是条件问题：在截止后点击相近的前提下，还有什么不同?

主要指标	配对	Fail − Pass	95% 区间	p	p_{Holm}	拒绝
截止时已提交	4768	-0.1235	[-0.135, -0.112]	0.0010	0.0060	是
截止后逾期提交	4768	0.0839	[0.072, 0.096]	0.0010	0.0060	是
提交日相对截止日	3859	1.3809	[1.182, 1.568]	0.0010	0.0060	是
后段活跃天数	4768	-0.3683	[-0.440, -0.295]	0.0010	0.0060	是
最长无点击间隔	4768	0.3888	[0.303, 0.473]	0.0010	0.0060	是
第二周点击占比	4768	-0.0368	[-0.050, -0.024]	0.0010	0.0060	是

表 3: 六项预先指定的配对差值，附学生关联组件 bootstrap 区间，以及族内 Holm 校正。负数表示 Fail 一侧更低。提交距离只在双方都在截点前提交时有定义，所以它的配对更少。区间以实际发生的配对为条件。

六项指标方向一致，且都不接近零。Fail 记录更不可能在截点前提交、更可能逾期提交；在已提交者中提交得更晚；截止之后活跃天数更少、沉默更长、第二周点击占比更低。Holm 校正后六项全部显著，因此故事的方向不取决于把哪一项当作主要指标。

提交分段	记录	Fail	通过或优秀	退课	Fail 占比
截点前未提交	2966	1507	478	981	75.9%
提前 7 天以上	1667	240	1270	157	15.9%
提前 1–6 天	11959	2056	8371	1532	19.7%
截止日当天	5373	1558	2789	1026	35.8%
逾期 1–7 天	1641	565	610	466	48.1%
逾期 8–14 天	519	166	196	157	45.9%

表 4: 按提交分段看结局构成。分段由掩蔽后的提交日构造，所以截点前没有提交的记录一律记为未提交到 $d + 14$，即使之后交了。

描述性差异很陡：截点前未提交的记录里有 75.9% 最终 Fail，而提前一周以上提交的只有 15.9%。这是描述而非因果——提交与结局都反映同一份努力——但它解释了为什么每个模型都保留提交状态。

4 预测信息

配对描述的是点击量相当时谁不同。另一个问题是：时机是否在点击量之外提供预测信息。模型阶梯在学生分组 60/20/20 切分上拟合（没有任何学生跨两部分），阈值在验证集上选择，再把训练加验证重新拟合后对测试集打分。

模型	特征数	Fail AP	无技能 AP	ROC-AUC	Brier	校准斜率	F1
M0	7	0.6544	0.3078	0.7585	0.1658	0.909	0.472
M1	14	0.6574	0.3078	0.7606	0.1651	0.912	0.477
M2	16	0.6611	0.3078	0.7647	0.1641	0.918	0.475
M3	36	0.6608	0.3078	0.7653	0.1640	0.912	0.470
RF_M0	7	0.6541	0.3078	0.7576	0.1904	0.897	0.473
RF_M2	16	0.6649	0.3078	0.7681	0.1853	0.944	0.464

表 5: 分组主测试集上的模型阶梯。M0 = 截止前后点击量 + 提交状态；M1 加后段时间特征；M2 加提交距离，是主模型；M3 加资源构成。M4（加首次 TMA 成绩）因冻结配置把成绩排除在严格特征之外而未列入，只作为回顾性上界单独讨论。阈值在验证集上选择。

主模型的 Fail AP 是 0.6611，无技能基线是 0.3078。阶梯说明了增益来自哪里：M0 已含提交状态，达到 0.6544；后段时间块把它推到 0.6574；提交距离项再加到 0.6611。也就是说，大部分预测信号是提交状态，而不是点击序列的细结构。梯度提升替代模型与之在噪声范围内，说明线性模型没有漏掉明显的非线性模式。

截止后天数	模型	Fail AP	Brier
1	M0	0.6380	0.1688
1	M1	0.6380	0.1688
1	M2	0.6449	0.1671
7	M0	0.6419	0.1685
7	M1	0.6414	0.1685
7	M2	0.6465	0.1672
14	M0	0.6536	0.1658
14	M1	0.6568	0.1652
14	M2	0.6604	0.1642

表 6: 同一切分上的观察窗曲线。窗口越长信息越多，所以 AP 上升；这不是方法上的增益，不能这样读。

把截点从 $d+1$ 移到 $d+14$，主模型的 AP 从 0.6449 升到 0.6604，特征清单完全不变。所以这个提升是观察得更久换来的信息，不是模型更好。

5 验证设计

切分	训练	测试	训练 Fail 占比	测试 Fail 占比	学生重叠
main_train_test	11892	3944	30.7%	30.8%	0
main_train_val	11892	3970	30.7%	30.9%	0
temporal	8162	11028	33.2%	29.4%	0
group_kfold_0	15844	3962	30.7%	31.2%	0
group_kfold_1	15845	3961	30.7%	31.1%	0
group_kfold_2	15845	3961	30.8%	30.4%	0
group_kfold_3	15845	3961	30.9%	30.3%	0
group_kfold_4	15845	3961	30.7%	30.8%	0
lomo_AAA	19196	608	31.3%	14.0%	0
lomo_BBB	14362	5439	30.5%	31.6%	0
lomo_CCC	16216	2438	31.5%	31.8%	0
lomo_DDD	15512	3894	30.1%	34.3%	0
lomo_EEE	17067	2197	31.1%	25.2%	0
lomo_FFF	14294	5230	30.6%	31.1%	0

表 7: 所有切分都按学生 ID 分组：没有任何学生同时出现在两侧。重叠列在构造上恒为零，并在运行时被断言。留一课程外推只有 6 折而不是 7 折，因为只有 6 门课有正权重 TMA。

6 稳健性与范围

规格	后段天数	容差	按什么匹配	配对	Fail 覆盖率	前段 SMD
primary	14	5%	post_clicks	4768	78.3%	-0.287
tolerance_0	14	0%	post_clicks	4118	67.6%	-0.306
tolerance_10	14	10%	post_clicks	4858	79.7%	-0.279
window_21_post	21	5%	post_clicks	4621	75.9%	-0.215
window_28_post	28	5%	post_clicks	4391	72.1%	-0.152
window_21_total	21	5%	total_clicks	4627	76.0%	0.051
window_28_total	28	5%	total_clicks	4477	73.5%	0.077
dedupe_events	14	5%	post_clicks	4779	78.4%	-0.268

表 8: 稳健性曲线。+21/+28 的两个变体各出现两次：按截止后点击配对（与主设计可比）和按全窗口点击配对（与早期的 +21/+28 研究可比）。两者回答不同问题，不能互相排名。

风险集中的最终结局	记录	占比
Fail	6092	25.3%
Pass	13714	56.8%
Withdrawn	4319	17.9%

表 9: 风险集把退课保留为独立类别。它与二分类比较是不同人群、不同问题。

所示指标在 8 个规格里符号全部一致，包括两个按不同量匹配的全窗口变体。幅度会动：按总点击匹配后截止后的差值变小，这是预期内的，因为全窗口总量本身有一部分是截止前的量。风险集描述是唯一建模退课的地方。把二分类结论当作退课预警是错的：那些记录在截点时仍在读，而预测幸存者里谁不及格和标记可能离开的人不是同一个模型。

7 局限

- AP 是 Fail 的平均精确率，不是准确率；无技能参照是同一批测试记录里的 Fail 占比。
- 配对是设计出来的 1:1，不能估计总体不及格率。贪心顺序不保证全局最优，bootstrap 只在实际配对上重抽学生，因此不含重新配对的不确定性。
- 二分类队列排除了截点前退课的记录，因此不是实时预警人群。
- 首次 TMA 成绩本身参与最终结果；用它的模型只是回顾性上界，OULAD 也没有成绩公布日。
- OULAD 的切分在多轮探索中被反复查看，所以区间与增量都是探索性的，即使协议已经冻结。
- VLE 的活动类型是平台类别，不等于内容质量；日粒度点击次数无法换算学习时长。

有两点必须在答辩时强调。第一，截止前窗口没有被主配对均衡，把它也均衡的敏感性只剩很小一部分配对，所以诚实的说法是比较固定了截止后点击量，并报告截止前历史仍差多少。第二，时间特征带来的增益很小。截止后持续性在描述上区分结局，远比它在预测上改善模型来得清楚；改善最多的那个模型加的是提交距离，而提交距离本身就是截止行为，不是点击模式。

披露

AIGC 工具参与了代码脚手架、文字编辑与 LaTeX 排版。全部分析代码、数值结果与论断均由全组复核，每一张图表都由流水线从公开数据重新生成。没有外部合作者提供数据或结果。

数据与代码可用性

未经修改的 OULAD 压缩包随仓库提交并附 SHA-256。解压后的 CSV、学生级特征、配对索引与预测不进入版本控制。一条命令即可复现分析；提交用的 ZIP 包含代码、冻结配置与运行日志。

A 探索性扩展

主分析冻结之后又跑了四个探索块。它们不改变任何主要指标或主模型，因此放在附录而不是正文。

协变量	类型	配对前 SMD	配对后 SMD	|SMD| ≤0.10
gender	分类	-0.056	-0.056	是
age_band	分类	-0.168	-0.043	是
highest_education	分类	-0.331	-0.360	否
imd_band	分类	0.180	0.161	否
disability	分类	0.072	0.072	是
num_of_prev_attempts	数值	0.261	0.195	否
studied_credits	数值	0.075	0.005	是

表 10: 配对样本的入学前协变量。配对本来就只均衡截止后点击，所以这里的残差是预期内的，报告而不修正。

最大的残差不平衡是 highest_education 的 -0.360 个标准差；教育程度、IMD 分带与先前尝试次数仍是最不平衡的几项。若再要求教育与 IMD 完全一致，只剩 3.3% 的配对，太少，不能替代主比较。在这个子集上，活跃天数差为 -0.148 天，区间明显更宽：方向保持，精度不足。

指标	固定配对估计	重配对均值	重配对 95% 区间
post_active_days	-0.368	-0.399	[-0.455, -0.347]
post_longest_inactive_run	0.389	0.412	[0.353, 0.476]

表 11: 重新配对的不确定性：每个重复都重抽学生、重建队列、重跑贪心配对，因此区间包含配对本身的不确定性。重复次数不多，是宽度检查，不是定论。

两项指标在重配对下符号与幅度都保持，区间只略微变宽，说明配对选择不是结论的来源。

结局	记录	占未提交者比例
Fail	1507	50.8%
退课	981	33.1%
通过	478	16.1%

表 12: 截点前未提交记录的结局分布。这是二分类比较无法覆盖的子群，因为退课与未提交在这里高度重叠。

2,966 条截点前未提交的记录中，33.1% 最终退课，50.8% 不及格。所以未提交更像离开的信号而不是失败的信号——这正是二分类要排除退课的原因。

模型	测试记录	Fail 或退课占比	AP	ROC-AUC	Brier
M0	4857	43.8%	0.7483	0.7603	0.1920
M1	4857	43.8%	0.7518	0.7634	0.1908
M2	4857	43.8%	0.7549	0.7675	0.1896

表 13: 预警目标：截点时在读者的 Fail 或退课，把退课当作正例。人群与标签都与二分类不同，AP 不可与第 4 节比较。

B 探索扩展的验证

附录 A 的内容都是探索性的。之后补了四项检查，看其中哪一条站得住：预注册的增量检验、外推汇总、带最小可检测效应的子群审计，以及两个负对照（延迟分型与日序）。它们都不改变任何主要数字。

增量臂	特征数	Fail AP
M2_frozen_baseline	16	0.66108
M2_plus_deep_frozen	24	0.66133
M2_plus_deep_deduplicated	20	0.66122
Δ deep_deduplicated_minus_baseline	–	+0.00016
Δ deep_minus_baseline	–	+0.00027

表 14: 预注册的增量检验（协议在运行前冻结）。判定规则是区间不含零且点估计不低于 0.005；两个臂都不满足，因此深度指标没有带来可辨别的预测信息。

冻结臂把 Fail AP 从 0.66108 移到 0.66133，差值为 +0.00027，95% 区间 [-0.00039, +0.00095]。剔除与主特征完全重复的两列后，结论相同。

切分	测试记录	Fail 占比	Fail AP	AP − 无技能
temporal	11028	29.4%	0.6160	0.322
lomo_AAA	608	14.0%	0.4432	0.303
lomo_BBB	5439	31.6%	0.6523	0.337
lomo_CCC	2438	31.8%	0.5997	0.282
lomo_DDD	3894	34.3%	0.6760	0.333
lomo_EEE	2197	25.2%	0.6800	0.428
lomo_FFF	5230	31.1%	0.6700	0.359

表 15: 主模型的外推汇总。折间原始 AP 不可比，因为 Fail 占比从 0.14 到 0.34，可比的是最后一列。CCC 没有 2013 批次，所以时间外推同时部分是跨课程。

属性	特征集	AUC 差	95% 区间	MDE（80% 功效）	过 BH
gender	仅行为	0.043	[0.009, 0.080]	0.034	否
gender	全部特征	0.051	[0.017, 0.082]	0.034	是
imd_band	仅行为	-0.011	[-0.051, 0.027]	0.041	否
imd_band	全部特征	-0.011	[-0.047, 0.027]	0.041	否
highest_education	仅行为	-0.015	[-0.055, 0.019]	0.037	否
highest_education	全部特征	-0.016	[-0.052, 0.022]	0.037	否
disability	仅行为	-0.009	[-0.063, 0.052]	0.061	否
disability	全部特征	-0.009	[-0.064, 0.046]	0.061	否
age_band	仅行为	0.041	[-0.000, 0.078]	0.036	否
age_band	全部特征	0.036	[-0.000, 0.075]	0.036	否

表 16: 子群审计。差值小于最小可检测效应，意思是样本量分辨不出来，不等于没有差异。bootstrap 的 p 值下限是 1 除以重复次数，落在下限的对比只能说在 bootstrap 分辨率内显著。

10 个对比中有 1 个通过 BH 校正：gender（全部特征，差 +0.051，BH p 0.025）。另有 7 个对比的差值小于最小可检测效应，这些属于未能检出，而不是不存在。两个负对照补完了图景。附录 A 的延迟剖面无法检验文献里高成就、低成就、偶发延迟者的三分型：聚类跑在（提交分数，窗口长度）上，而窗口长度强烈双峰，剖面几乎是窗口长度的切分。诚实的说法是这套操作化分不开延迟与窗口长度，而不是分型本身错了。

序列臂	特征数	Fail AP	ROC-AUC
mlp_ordered_daily	20	0.5472	0.7105
mlp_shuffled_daily	20	0.5495	0.7115
mlp_bag_summary	8	0.5556	0.7125
mlp_ordered_plus_M2	34	0.6550	0.7562
mlp_bag_plus_M2	22	0.6562	0.7592
M2_logistic_reference	16	0.6611	0.7647

表 17: 同一切分上的日序对照。PyTorch 装不上，所以在有序日向量上用的是前馈网络而不是循环网络；关键对比是有序与打乱。

打乱 14 天的日向量使 Fail AP 变化 -0.0022（-0.0073 至 0.0031），说明日的顺序没有携带多重集之外的信息。这不能否定已发表的序列模型结果——那些用不同的标签、不同的切分；只能说在本设计里，序列表示没有增加什么。

C 复现

```
make test
make sim && make validate RUN_ID=$(cat .last_sim_run)
make full && make validate RUN_ID=$(cat .last_full_run)
```

每个阶段写入阶段摘要、交接说明与 JSONL 事件；校验器按 `docs/contracts` 的 schema 检查日志，要求 0 错误、0 警告。